

Laboratório 09 - Estatística Aplicada - Manhã

Aluno: Marcus Vinícius Leite
Costa

Matrícula: 116110728

1)

- a) Na letra A, foi-se utilizado os seguintes comandos para gerar os diagramas de dispersão entre as variáveis:

```
# QUESTAO 01

dados <- scan("vendas.dat",what=list(telhados=0, gastos=0,
clientes=0, marcas=0, potencial=0))
attach(dados)

# Letra A

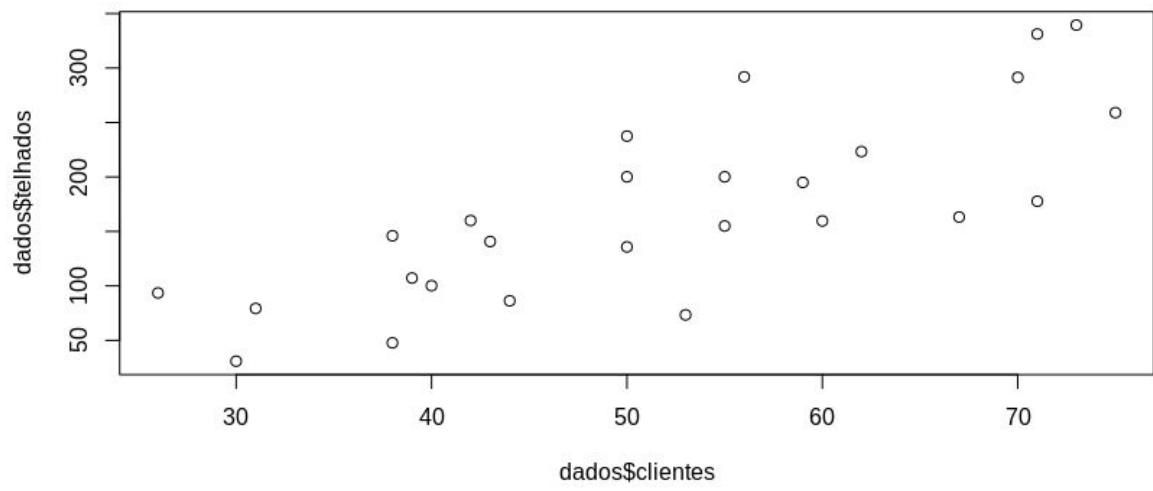
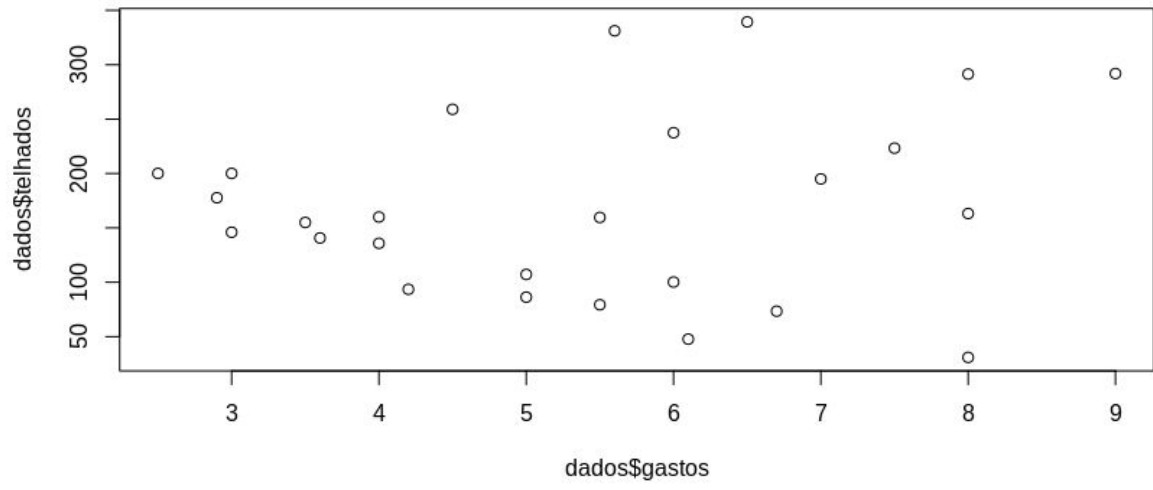
plot(x = dados$gastos , y = dados$telhados)

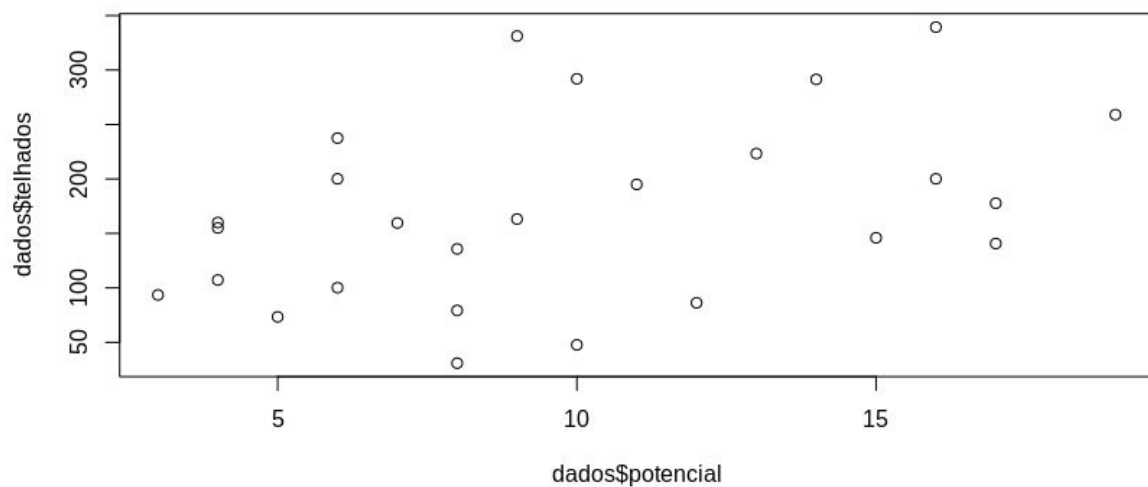

plot(x = dados$clientes , y = dados$telhados)

plot(x = dados$marcas , y = dados$telhados)

plot(x = dados$potencial , y = dados$telhados)
```

Os diagramas de dispersão gerados foram os seguintes:





b) Na letra B, foi-se utilizado um comando que plota uma matriz de correlação entre todas as variáveis, o comando foi o seguinte:

```
cor(matrix(unlist(dados), nrow=26))
```

E a matriz obtida foi:

	[,1]	[,2]	[,3]	[,4]	[,5]
[1,]	1.0000000	0.15886840	0.7828441	-0.83298059	0.4072695
[2,]	0.1588684	1.00000000	0.1725506	-0.03825157	-0.0705647
[3,]	0.7828441	0.17255062	1.0000000	-0.32428751	0.4682129
[4,]	-0.8329806	-0.03825157	-0.3242875	1.00000000	-0.2020604
[5,]	0.4072695	-0.07056470	0.4682129	-0.20206035	1.0000000

Onde a posição 1,2,3,4,5 é referente às variáveis telhados, gastos, clientes, marcas e potencial respectivamente.

c) Na letra C, primeiramente foi-se utilizado os comandos para adicionar as variáveis ao modelo em ordem de correlação (calculada anteriormente)

```
lm1 <- lm(telhados ~ marcas)
lm2 <- lm(telhados ~ marcas+clientes)
lm3 <- lm(telhados ~ marcas+clientes+potencial)
lm4 <- lm(telhados ~ gastos+clientes+marcas+potencial)
```

Após obter-se os modelos, foi-se utilizado o comando summary para gerar as tabelas anova, os resultados obtidos foram os seguintes:

```
> summary(lm1)

Call:
lm(formula = telhados ~ marcas)

Residuals:
    Min       1Q   Median       3Q      Max
-107.133  -31.444    4.195   32.570   86.178

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  418.854   34.990   11.971 1.31e-11 ***
marcas       -27.278    3.699   -7.375 1.29e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 47.75 on 24 degrees of freedom
Multiple R-squared:  0.6939,    Adjusted R-squared:  0.6811
F-statistic: 54.39 on 1 and 24 DF,  p-value: 1.29e-07

> summary(lm2)

Call:
lm(formula = telhados ~ marcas + clientes)

Residuals:
    Min       1Q   Median       3Q      Max
```

```
-18.4136 -6.1499 -0.5683 6.2472 20.3185
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	186.6940	12.2587	15.23	1.66e-13 ***
marcas	-21.1930	0.8028	-26.40	< 2e-16 ***
clientes	3.4081	0.1458	23.37	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.803 on 23 degrees of freedom

Multiple R-squared: 0.9876, Adjusted R-squared: 0.9866

F-statistic: 918.3 on 2 and 23 DF, p-value: < 2.2e-16

```
> summary(lm3)
```

Call:

```
lm(formula = telhados ~ marcas + clientes + potencial)
```

Residuals:

Min	1Q	Median	3Q	Max
-17.5324	-5.5272	-0.5563	5.7107	20.4942

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	186.1147	12.5759	14.799	6.44e-13 ***
marcas	-21.1735	0.8194	-25.840	< 2e-16 ***
clientes	3.3798	0.1650	20.488	8.05e-16 ***
potencial	0.1892	0.4791	0.395	0.697

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.988 on 22 degrees of freedom

Multiple R-squared: 0.9877, Adjusted R-squared: 0.986

F-statistic: 589.8 on 3 and 22 DF, p-value: < 2.2e-16

```
> summary(lm4)
```

Call:

```
lm(formula = telhados ~ gastos + clientes + marcas + potencial)
```

```

Residuals:
      Min       1Q   Median       3Q      Max
-19.0906  -5.9796   0.8968   6.5667  14.7985

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  178.3203   12.9603   13.759 5.62e-12 ***
gastos       1.8071     1.0810    1.672  0.109
clientes     3.3178     0.1629   20.368 2.60e-15 ***
marcas      -21.1850     0.7879  -26.887 < 2e-16 ***
potencial    0.3245     0.4678    0.694  0.495
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.604 on 21 degrees of freedom
Multiple R-squared:  0.9892,    Adjusted R-squared:  0.9871
F-statistic: 479.1 on 4 and 21 DF,  p-value: < 2.2e-16

```

d) O melhor modelo obtido foi aquele após acrescentar as variáveis marcas e clientes por possuir o menor p-valor, com uma baixa quantidade de resíduos.

2)

a) Os vetores X e Y foram obtidos a partir dos seguintes comandos:

```

# QUESTAO 2

# Letra A

data2 <- matrix(c(37.310,
37.380,34.135,36.985,38.715,40.620,39.200,40.320,10,5,3,6,8,20,8,1
4,2,6,1,5,8,0,4,6,16,16,12,14,16,12,18,17), nrow = 8 , ncol =4 ,
byrow = FALSE)

vetor_x = matrix(c(1,1,1,1,1,1,1,1,37.310,
37.380,34.135,36.985,38.715,40.620,39.200,40.320,10,5,3,6,8,20,8,1
4,2,6,1,5,8,0,4,6,16,16,12,14,16,12,18,17), nrow = 8 , ncol =5 ,

```

```
byrow = FALSE)

vetor_y = c(37.310,
37.380,34.135,36.985,38.715,40.620,39.200,40.320)
```

Os resultados dos vetores X e Y, respectivamente, foram os seguintes:

	[,1]	[,2]	[,3]	[,4]	[,5]
[1,]	1	37.310	10	2	16
[2,]	1	37.380	5	6	16
[3,]	1	34.135	3	1	12
[4,]	1	36.985	6	5	14
[5,]	1	38.715	8	8	16
[6,]	1	40.620	20	0	12
[7,]	1	39.200	8	4	18
[8,]	1	40.320	14	6	17

```
[1] 37.310 37.380 34.135 36.985 38.715 40.620 39.200 40.320
```

b) A equação para calcular a reta foi obtida a partir da função:

```
beta <- solve(t(vetor_x) %*% vetor_x) %*% (t(vetor_x) %*% vetor_y)

modelo_matriz = function(beta1,x1,x2,x3){beta[1,] + beta[2,]*x1 +
beta[3,]*x2 + beta[4,]*x3}
```

c) O salário previsto, utilizando a seguinte função, foi 36.20141

```
modelo_matriz(beta[1,],7,3,12)
```

```
modelo_matriz = function(beta1,x1,x2,x3){beta[1,] + beta[2,]*x1 +
beta[3,]*x2 + beta[4,]*x3}
```

d) Chamando a função modelo_matriz, foi-se obtido o y_chapeu da seguinte forma:

```

y_chapeu = c(modelo_matriz(beta =
beta[1,],vetor_x[1,2],vetor_x[1,3],vetor_x[1,4]),
              modelo_matriz(beta =
beta[1,],vetor_x[2,2],vetor_x[2,3],vetor_x[2,4]),
              modelo_matriz(beta =
beta[1,],vetor_x[3,2],vetor_x[3,3],vetor_x[3,4]),
              modelo_matriz(beta =
beta[1,],vetor_x[4,2],vetor_x[4,3],vetor_x[4,4]),
              modelo_matriz(beta =
beta[1,],vetor_x[5,2],vetor_x[5,3],vetor_x[5,4]),
              modelo_matriz(beta =
beta[1,],vetor_x[6,2],vetor_x[6,3],vetor_x[6,4]),
              modelo_matriz(beta =
beta[1,],vetor_x[7,2],vetor_x[7,3],vetor_x[7,4]),
              modelo_matriz(beta =
beta[1,],vetor_x[7,2],vetor_x[8,3],vetor_x[8,4]))

```

E os resultados para o vetor y e os dados do modelo são os seguintes:

```
> vetor_y
```

```
[1] 37.310 37.380 34.135 36.985 38.715 40.620 39.200 40.320
```

```
> y_chapeu
```



```
[1] 38.13476 37.22318 34.28852 36.82610 38.77165 40.25591 38.39505 38.58335
```



É possível observar que, os dados preditos estão bem próximos dos originais, logo, podemos deduzir que o modelo se ajusta bem aos dados.

e) Os resíduos obtidos foram os seguintes:

```
[1] -0.82476456 0.15682034 -0.15352139 0.15889720 -0.05665337 0.36409294
0.80495179 1.73664921
```

E ao rodar o Teste de Kolmogorov-Smirnov no modelo, foi-se observado os seguintes gráficos:





Ao observar os resultados dos resíduos, e também, os gráficos (pressupostos teóricos), podemos deduzir que o modelo se adaptou bem aos dados. Essa dedução é feita observando, primeiramente, o valor dos resíduos, que normalmente

são baixos, e também, observando-se os gráficos, como por exemplo, no Q-Q Plot, que mostra claramente que não existem pontos distantes da curva.